

# **KLASIFIKASI PENYAKIT HATI MENGGUNAKAN DEEP NEURAL NETWORK**

Disusun untuk memenuhi tugas mata akhir kuliah  
Kecerdasan Buatan



## **DISUSUN OLEH :**

Nofi Ayu Wulandari	23051204326
Muhammad Alvi K.Z.N	23051204339

## **DOSEN PENGAMPU :**

Dr. Ir. Ricky Eka Putra, S.Kom., M.Kom.,

**PROGRAM STUDI TEKNIK INFORMATIKA  
FAKULTAS TEKNIK  
UNIVERSITAS NEGERI SURABAYA  
2024/2025**

## **A. PENDAHULUAN**

Penyakit jantung merupakan salah satu masalah kesehatan yang paling serius di dunia. Penyakit ini menyerang organ jantung, yang berfungsi vital untuk memompa darah dan mendistribusikan oksigen ke seluruh tubuh. Penyakit jantung dapat disebabkan oleh berbagai faktor, seperti pola makan yang tidak sehat, gaya hidup sedentari, riwayat keluarga, tekanan darah tinggi, diabetes, dan kebiasaan merokok. Dalam banyak kasus, penyakit ini muncul secara perlahan tanpa gejala yang jelas hingga mencapai tahap yang serius.

Menurut laporan organisasi kesehatan, penyakit jantung tetap menjadi penyebab utama kematian di berbagai negara, baik di negara maju maupun berkembang. Deteksi dini dan pengelolaan yang tepat menjadi kunci dalam mencegah komplikasi yang lebih serius, seperti serangan jantung atau gagal jantung. Namun, pendekatan tradisional untuk diagnosis penyakit jantung sering kali memerlukan proses yang rumit, memakan waktu, dan tidak selalu memberikan hasil yang akurat.

Di era digital saat ini, penggunaan teknologi berbasis kecerdasan buatan (artificial intelligence, AI), khususnya Deep Neural Network (DNN), memberikan peluang baru dalam diagnosis penyakit jantung. Teknologi ini mampu menganalisis data medis secara lebih cepat dan akurat, sehingga membantu dokter dalam pengambilan keputusan klinis. Dengan memanfaatkan model DNN, klasifikasi penyakit jantung dapat dilakukan secara efisien, memberikan peluang besar untuk deteksi dini dan perawatan yang lebih baik.

Penelitian ini bertujuan untuk menerapkan metode Deep Neural Network (DNN) dalam klasifikasi penyakit jantung, menguji efektivitasnya, dan mengevaluasi potensi penerapan teknologi ini di dunia medis. Diharapkan, pendekatan ini dapat menjadi langkah inovatif dalam mendukung pengelolaan penyakit jantung secara lebih efisien dan akurat.

## B. TINJAUAN PUSTAKA

### 1. Penyakit Hati

Penyakit hati mencakup berbagai kondisi yang memengaruhi fungsi hati. Beberapa jenis penyakit hati yang umum meliputi:

- **Hepatitis:** Peradangan hati yang disebabkan oleh infeksi virus atau paparan zat beracun
- **Sirosis:** Kondisi kronis di mana jaringan hati digantikan oleh jaringan parut, sehingga mengganggu fungsi normal hati.
- **Kanker Hati:** Biasanya berkembang sebagai komplikasi sirosis atau infeksi hepatitis kronis.

Faktor risiko penyakit hati meliputi gaya hidup tidak sehat, konsumsi alkohol berlebih, infeksi virus hepatitis B dan C, serta obesitas. Diagnosis dini penyakit hati sangat penting untuk menentukan langkah pengobatan yang tepat. Teknologi seperti DNN dapat membantu dalam mengklasifikasikan kondisi hati berdasarkan data medis, seperti enzim hati, hasil pencitraan, atau riwayat medis pasien.

### 2. SMOTE

Salah satu tantangan dalam analisis data medis adalah ketidakseimbangan kelas, di mana jumlah data pada kategori tertentu (seperti pasien dengan penyakit hati) jauh lebih sedikit dibandingkan kategori lainnya (pasien sehat). Ketidakseimbangan ini dapat menyebabkan model pembelajaran mesin bias terhadap kelas mayoritas.

SMOTE adalah teknik untuk menangani ketidakseimbangan data dengan menciptakan data sintesis pada kelas minoritas. Proses SMOTE melibatkan interpolasi antara sampel minoritas untuk menghasilkan data baru yang realistis. Teknik ini efektif dalam meningkatkan akurasi model pembelajaran mesin, termasuk DNN, ketika menghadapi dataset yang tidak seimbang.

### 3. DNN

Arsitektur jaringan saraf tiruan yang terdiri dari beberapa lapisan tersembunyi. DNN dirancang untuk mempelajari representasi data yang kompleks melalui proses hierarkis. Setiap lapisan bertanggung jawab untuk mengekstraksi fitur tertentu dari data input,

sehingga memungkinkan model untuk memahami hubungan non-linear antara fitur.

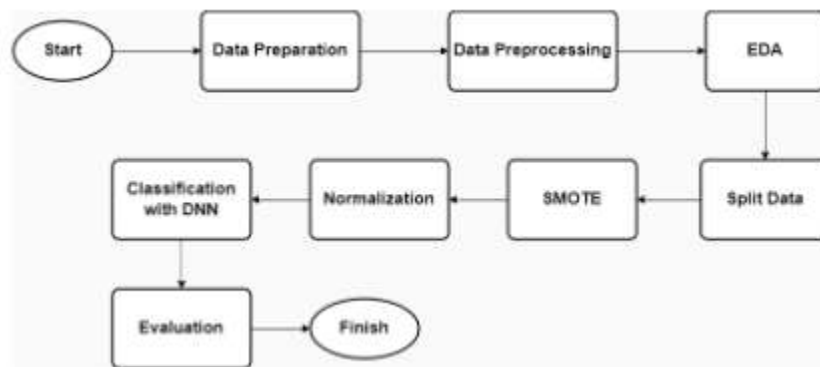
Keunggulan DNN dalam klasifikasi penyakit hati adalah kemampuannya untuk:

- Mengolah data medis yang kompleks dan tidak terstruktur.
- Meningkatkan akurasi diagnosis melalui identifikasi pola-pola yang tidak terlihat oleh metode tradisional.
- Mengintegrasikan berbagai sumber data, seperti tes laboratorium, citra medis, dan riwayat pasien.

## C. METODOLOGI

### 1. Alur Diagram

Sebelum membangun sebuah model adalah dengan menentukan sebuah alur dari pembangun program sesuai dengan journal yang digunakan sebagai dasar acuan pembangunan model ada beberapa tahapan yang perlu dilakukan. Untuk tahapan bisa dilihat pada gambar dibawah ini



Berdasarkan gambar tersebut, tahap pertama dalam membangun sebuah model adalah menyiapkan data, dilanjutkan dengan proses pembersihan data yang mencakup penghapusan data duplikat dan data kosong. Setelah itu, dilakukan *Exploratory Data Analysis* (EDA) untuk menganalisis atribut, termasuk memeriksa apakah atribut-atribut tersebut memiliki korelasi dengan target. Atribut yang telah melalui proses pembersihan kemudian memasuki tahap berikutnya, yaitu proses SMOTE (*Synthetic Minority Oversampling Technique*) untuk menyeimbangkan data pelatihan, diikuti oleh normalisasi yang mengubah rentang nilai atribut menjadi lebih kecil, biasanya antara 0–1. Selanjutnya, model DNN (*Deep Neural Network*) dibangun, dan tahap terakhir adalah melakukan evaluasi terhadap model yang telah dibuat.

### 2. Data Preparation

Pada tahap ini dilakukan data yang digunakan adalah data dari kaggle yang dimana data tersebut memiliki 14 Atribut termasuk usia, jenis kelamin, tipe nyeri dada, tekanan darah pasien, kadarkolesterol, detak jantung maksimum, gula darah puasa, angina yang dipicu oleh olahraga, hasil elektrokardiografi (ECG) saat istirahat, depresi ST,

kemiringan ST, thalassemia, jumlah pembuluh darah yang diwarnai menggunakan fluoroskopi, dan target [12]. Informasi rinci mengenai karakteristik dataset dijelaskan pada tabel dibawah ini:

Name	Type	Description
age	integer	Patient age
sex	categorical	0 = female dan 1= male
cp	categorical	Type of chest pain (1: typical angina, 2: atypical angina, 3: non-anginal pain, 4: asymptomatic)
trestbps	integer	Resting blood pressure (mm Hg)
chol	integer	Serum cholesterol (mg/dl)
fbs	categorical	Fasting blood sugar >120 mg/dl (0: no, 1: yes)
restecg	categorical	ECG results at rest (0: normal, 1: ST-T wave abnormality, 2: left ventricular hypertrophy)
thalach	integer	Max heart rate
exang	categorical	Exercise induced angina (0: no, 1: yes)
oldpeak	integer	Exercise induced depression
slope	categorical	Slope of peak training ST segment (1: uphill, 2: flat, 3: downhill)
ca	integer	Number of blood vessels stained by fluoroscopy
thal	categorical	Thalium voltage test results (3: standard, 6: fixed, 7: reversible defect)
target	integer	Heart disease potential status (0: no, 1: yes)

### 3. Data Preprocessing

Data preprocessing adalah sebuah tahapan untuk membersihkan sebuah data dari missing value dan juga menghapus data yang duplikat. Karena dengan membersihkan sebuah data dari missing value dan data duplikat bisa meningkatkan akurasi model dan mencegah bias dalam analisa dalam tahap ini program yang digunakan adalah python menggunakan library pandas

### 4. Exploraty Data Analysis ( EDA )

Tahap Exploratory Data Analysis (EDA) bertujuan untuk menganalisis dan memahami pola data sebelum membangun model klasifikasi penyakit jantung. Proses EDA yang dilakukan mencakup dua jenis analisis, yaitu analisis univariat dan multivariat. Analisis univariat dilakukan untuk memahami distribusi setiap variabel dalam dataset. Analisa Mutivariat digunakan untuk melihat korelasi antar variabel dalam dataset apabila nilai korelasi antar variabel beserta pengaruhnya terhadap variabel tersebut

### 5. Synthetic Minority Over-sampling Technique ( SMOTE )

SMOTE adalah sebuah teknik yang digunakan untuk menyeimbangkan kelas dalam sebuah dataset. Ketidakseimbangan sebuah kelas dalam dataset terjadi ketika jumlah sampel kelas pada sebuah dataset kurang atau lebih dari sampel kelas lain. Ketidakseimbangan sebuah sampel data dapat menyebabkan sebuah bias dalam analisa. SMOTE sendiri memiliki sebuah formula berikut:

$$X_{syn} = X_i + (X_{knn} - X_i) \times \delta$$

Notes:

$X_{syn}$  = Data synthesis to be created

$X_i$  = Data to be replicated

$X_{knn}$  = Data that hisfarfrom data  $X_i$

$\delta$  = random number between 0 and 1


## 6. Normalisasi

Normalisasi Datat Adalah salah satu langkah penting sebelum melakukan training pada model. Berikut adalah hasil parafrase dan terjemahan ke dalam bahasa Indonesia:


Metode normalisasi yang umum digunakan adalah *StandardScaler*. *StandardScaler* berasal dari pustaka *Scikit-learn* dan berfungsi untuk mereskalakan fitur dalam sebuah dataset dengan cara mengurangi nilai rata-rata (mean) dari setiap fitur, kemudian menskalakannya ke dalam varians satuan (\*unit variance\*). Dalam penelitian ini, *StandardScaler* digunakan untuk mengurangi pengaruh outliers dan meningkatkan konsistensi skala fitur setelah penerapan teknik SMOTE. Berikut adalah rumus untuk normalisasi menggunakan *StandardScaler*:

$$X_{stand} = x - \frac{mean(x)}{standard\ deviation(x)}$$

## 7. Classification Using Deep Neural Network (DNN)



Deep Neural Network (DNN) adalah jenis arsitektur jaringan saraf yang terdiri dari banyak lapisan yang saling terhubung. Proses pelatihan DNN melibatkan mekanisme



feedforward dan backpropagation. Dalam proses feedforward, data dari lapisan masukan (input layer) akan dipropagasi ke depan melalui lapisan tersembunyi (hidden layers) hingga mencapai lapisan keluaran (output layer). Sementara itu, backpropagation digunakan untuk memperbarui bobot pada setiap koneksi neuron dengan menghitung gradien kesalahan dari lapisan keluaran ke lapisan masukan.

Struktur DNN dapat dibagi menjadi tiga jenis lapisan, yaitu lapisan masukan (input layer), lapisan tersembunyi (hidden layers), dan lapisan keluaran (output layer). Setiap lapisan tersembunyi memiliki neuron-neuron yang saling terhubung untuk mengekstraksi pola fitur dari data.

Penelitian ini dilakukan untuk menemukan model terbaik dalam klasifikasi penyakit jantung. Model terbaik yang diperoleh kemudian digunakan untuk melakukan klasifikasi. Setiap lapisan dalam model menggunakan fungsi aktivasi ReLU (Rectified Linear Unit), yang membantu mengatasi masalah vanishing gradient dan meningkatkan efisiensi komputasi. Untuk mencegah overfitting, model menggunakan:

Regularisasi Kernel dengan L2 Regularization: Regularisasi ini menambahkan penalti terhadap bobot yang terlalu besar, sehingga model menjadi lebih generalisasi.

Dropout Layer: Model menyertakan dropout layer dengan nilai 0.5, yang secara acak "mematikan" sejumlah neuron selama proses pelatihan untuk mengurangi ketergantungan pada neuron tertentu.

Early Stopping: Teknik ini memantau metrik val\_loss selama pelatihan. Jika val\_loss tidak mengalami penurunan selama 10 epoch berturut-turut, pelatihan akan dihentikan lebih awal untuk mencegah overfitting.

Adam (Adaptive Moment Estimation) adalah metode optimisasi yang menggabungkan algoritma Momentum dan RMSprop. Adam merupakan pengembangan dari metode Stochastic Gradient Descent (SGD) yang telah memperbaiki estimasi adaptif dari momen orde pertama dan kedua. Rumus perhitungan Adam adalah sebagai berikut:



$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\hat{v}_t + \varepsilon}} \cdot \hat{m}_t$$

Notes:

- $\theta_{t+1}$  = Parameter update result
- $\theta_t$  = Previous update result parameter
- $\eta$  = Learning rate
- $\hat{v}_t$  = Squared gradient of second-order moments
- $\varepsilon$  = Small scalar to prevent division by zero
- $\hat{m}_t$  = Squared gradient of the first moment

Model tersebut terdiri dari:

Parameters	Value	Parameters	Value
Number of layers	8	Number of neurons in the output layer	1
Number of neurons in the input layer	64	Regularizer kernel L2	0.001
Number of neurons in hidden layer 1	128	Learning Rate	0.001
Number of neurons in hidden layer 2	256	Epoch	50
Number of neurons in hidden layer 3	512	Batch Size	16
Number of neurons in hidden layer 4	256		
Number of neurons in hidden layer 5	128		
Dropout	0.5		

## 8. Evaluasi

Model Evaluasi model sangat penting digunakan untuk mengukur model yang di latih. Ini penting untuk mengerti apakah model yang kita latih itu akurat salah satunya dengan convulation matrik yang dimana terdapat beberapa komponen didalamnya. True Positive (TP), True Negative (TN), False Negative (NV) and False Positive (FP). Dan Cobvulation Matrik biasanya digunakan untuk akurasi, presisi, recall, dan f1-score:


$$\begin{aligned}
 akurasi &= \frac{TP + TN}{TP + TN + FP + FN} \\
 Presisi &= \frac{TP}{TP + FP} \\
 Recall &= \frac{TP}{TP + FN} \\
 F1 - Score &= 2 \times \frac{(Presisi \times recall)}{Precision + Recall}
 \end{aligned}$$

## D. HASIL DAN PEMBAHASAN

Data yang digunakan mengandung beberapa data set dimana dataset tersebut melewati proses preprocessing data meliputi pemberisihan data dari nilai nul dan data duplikat setelah itu melewati tahapan analisa data. Berdasarkan gambar dibawah ini

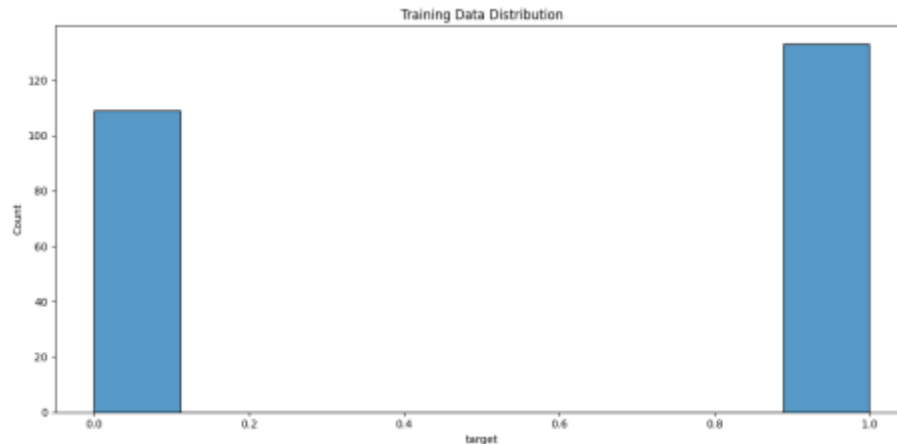


Korelasi positif berarti ketika nilai satu variabel meningkat, variabel lainnya cenderung ikut meningkat, misalnya *cp* (tipe nyeri dada) yang berkorelasi positif dengan *target*, menunjukkan bahwa semakin tinggi nilai *cp*, semakin besar kemungkinan seseorang menderita penyakit jantung. Sebaliknya, korelasi negatif terjadi ketika nilai satu variabel meningkat, variabel lainnya cenderung menurun, seperti *oldpeak* (depresi ST) yang berkorelasi negatif dengan *target*, artinya semakin tinggi nilai *oldpeak*, semakin kecil kemungkinan seseorang memiliki penyakit jantung. Korelasi ini membantu memahami hubungan antar variabel untuk memprediksi target dengan lebih akurat.



Berdasarkan gambar tersebut bisa dilihat kelas tidak penyakit jantung memiliki jumlah yang dominan dengan kelas penyakit jantung. Hal ini bisa menyebabkan tidak seimbangnya

sebuah data saat data tersebut dilakukan proses training. Setelah itu, data dibagi menjadi 80% data training dan 20% data testing untuk memastikan model dapat belajar dengan baik sekaligus mengukur performanya pada data yang belum pernah dilihat. Namun, jika distribusi data pada kelas target tidak seimbang, hal ini dapat menyebabkan model cenderung bias terhadap kelas mayoritas.



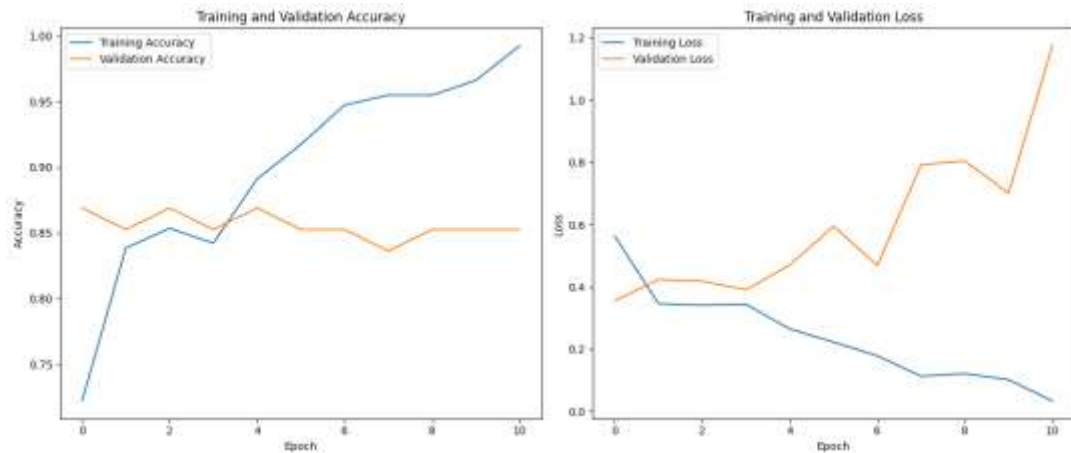
Untuk mengatasi masalah ini, dapat digunakan beberapa teknik seperti oversampling pada kelas minoritas, undersampling pada kelas mayoritas, atau menggunakan metode lain seperti SMOTE (Synthetic Minority Oversampling Technique). Teknik ini bertujuan untuk menciptakan keseimbangan antara kelas sehingga model dapat mempelajari pola dari kedua kelas dengan lebih baik. Selain itu, evaluasi model juga sebaiknya menggunakan metrik seperti precision, recall, dan F1-score yang lebih sesuai untuk data tidak seimbang dibandingkan akurasi semata. Setelah dilakukan SMOTE distribusi kelas bisa menjadi lebih seimbang




Kemudian data dilakukan normalisasi dengan menggunakan fungsi bawaan scikit learn yaitu StandardScaler. Kemudian data dilakukan normalisasi dengan menggunakan fungsi bawaan scikit-learn yaitu StandardScaler. Normalisasi ini bertujuan untuk menyetarakan skala dari setiap fitur dalam dataset, sehingga setiap fitur memiliki rata-rata 0 dan standar deviasi 1. Dengan normalisasi ini, model machine learning seperti algoritma berbasis gradient

descent dapat bekerja lebih optimal karena fitur yang memiliki skala besar tidak akan mendominasi proses training.

Setelah proses normalisasi dilakukan, data digunakan untuk melatih model klasifikasi



Grafik menunjukkan bahwa model mengalami **overfitting**, di mana training accuracy meningkat tajam dan training loss terus menurun, sedangkan validation accuracy stagnan di sekitar 85-87% dan validation loss justru meningkat signifikan setelah beberapa epoch. Hal ini mengindikasikan bahwa model terlalu fokus pada data pelatihan dan gagal melakukan generalisasi dengan baik pada data validasi meskipun sudah diterapkan regularisasi dan early stopping.





Evaluasi performa model dilakukan menggunakan metrik precision, recall, F1-score, dan accuracy, seperti yang ditunjukkan pada classification report di atas. Dari hasil tersebut, diperoleh skor **accuracy sebesar 87%** dengan nilai F1-score untuk kelas 0 sebesar **0.86** dan kelas 1 sebesar **0.88**, menandakan bahwa model memiliki performa yang cukup baik. Selain itu, untuk analisis lebih mendalam, confusion matrix juga digunakan sebagai visualisasi performa prediksi model. Berdasarkan confusion matrix di atas:

- Model berhasil mengklasifikasikan **25 sampel kelas 0** dengan benar (True Negative).
  - Model berhasil mengklasifikasikan **28 sampel kelas 1** dengan benar (True Positive).
  - Terdapat **4 kesalahan prediksi** untuk kelas 0 dan **4 kesalahan prediksi** untuk kelas 1.
- Dengan demikian, performa model menunjukkan keseimbangan yang baik dalam memprediksi kedua kelas, meskipun terdapat beberapa kesalahan prediksi yang dapat diatasi dengan tuning lebih lanjut atau metode balancing data lainnya jika diperlukan.

## E. KESIMPULAN

Dataset yang digunakan dalam penelitian ini telah melalui proses preprocessing data, termasuk pembersihan nilai null, penghapusan data duplikat, dan normalisasi menggunakan StandardScaler untuk menyetarakan skala fitur. Korelasi antara variabel menunjukkan hubungan positif dan negatif yang signifikan, seperti cp yang berkorelasi positif dengan target dan oldpeak yang berkorelasi negatif. Namun, distribusi kelas target tidak seimbang, di mana kelas tanpa penyakit jantung lebih dominan, yang dapat menyebabkan bias pada model. Masalah ini diatasi menggunakan teknik balancing seperti SMOTE, sehingga distribusi kelas menjadi lebih seimbang. Model kemudian dilatih menggunakan data yang telah dinormalisasi, dengan evaluasi performa menggunakan precision, recall, F1-score, dan accuracy. Hasil evaluasi menunjukkan akurasi sebesar 87%, dengan nilai F1-score yang cukup baik untuk kedua kelas (0.86 untuk kelas 0 dan 0.88 untuk kelas 1). Meskipun demikian, grafik menunjukkan adanya overfitting, di mana training accuracy terus meningkat tetapi validation accuracy stagnan. Berdasarkan confusion matrix, model berhasil mengklasifikasikan sebagian besar sampel dengan benar, meskipun masih terdapat beberapa kesalahan prediksi yang memerlukan perbaikan lebih

lanjut. Secara keseluruhan, model memiliki performa yang cukup baik dalam memprediksi kedua kelas.